

Trabalho N1 · Ciência de Dados

Aplicação Prática do Plotly nas Fases Iniciais do CRISP-DM

Um estudo de caso sobre cancelamento de reservas de hotel

FERRAMENTA DE BI

Plotly

INTEGRANTES

Henrique Cordeiro de Oliveira · Lucas Mendonça · Victor Kunz
Nicholas Scoz · Kauã Lucindo

Roteiro

Três partes, do conceito à crítica

1

Fundamentação teórica

O que é o Plotly, como se organiza, e como cada funcionalidade sustenta as três primeiras fases do CRISP-DM.

2

Estudo de caso prático

119 mil reservas de hotel: exploração, limpeza, engenharia de features e um dashboard interativo.

3

Análise crítica

O que o Plotly faz melhor que uma ferramenta de BI fechada — e o que faz pior.

O que é o Plotly

Biblioteca de visualização open-source, fundada em 2013 em Montreal

O Plotly nasceu como uma biblioteca JavaScript de gráficos e cresceu até virar um ecossistema completo de análise. O núcleo — plotly.js — é o mesmo que roda por baixo das bibliotecas para Python, R e Julia, o que explica por que o gráfico sai idêntico em qualquer linguagem.

É software livre sob licença MIT, mantido por uma empresa que monetiza a versão corporativa do Dash. Isso importa: não há custo de licença para o que usamos aqui.

Interatividade não é um extra: todo gráfico nasce com zoom, seleção, legenda clicável e exportação.

2013

Ano de fundação, em Montreal (Canadá)

MIT

Licença livre — sem custo de uso

4

Linguagens sobre o mesmo núcleo:
JavaScript, Python, R e Julia

Componentes e arquitetura

Cinco camadas — usamos quatro delas neste trabalho

1	plotly.js O motor. Biblioteca JavaScript que desenha e torna interativo cada gráfico.	Base
2	Plotly Express API de alto nível: um gráfico completo em uma linha de código.	Usado
3	Graph Objects Controle fino, para quando o Express não alcança. Usado no dashboard.	Usado
4	Dash Framework para transformar gráficos em aplicação web com filtros.	Usado
5	Chart Studio Editor visual no navegador: sobe CSV e monta gráfico sem escrever código.	Low-code

Posicionamento de mercado

Por que o Plotly não aparece no Quadrante Mágico do Gartner

A ausência é proposital

O Quadrante Mágico de Analytics and BI Platforms avalia plataformas completas: governança, catálogo de dados, modelagem, distribuição corporativa.

O Plotly não concorre nessa categoria. Ele é uma biblioteca de visualização — compará-lo ao Power BI é como comparar um motor a um carro.

Reconhecer isso é mais honesto do que forçar um enquadramento que não existe.

Público-alvo e casos de uso

1

Equipes de ciência de dados

Quem já trabalha em Python e precisa de gráfico interativo no notebook.

2

Aplicações analíticas sob medida

Dashboards com regra de negócio que uma ferramenta fechada não expressa.

3

Produtos com dados embutidos

Gráficos dentro de um sistema próprio, não num portal de BI separado.

4

Pesquisa e publicação

Figuras reproduzíveis, versionadas junto com o código que as gera.

01

CRISP-DM e o Plotly

Como cada funcionalidade da ferramenta sustenta as três primeiras fases da metodologia

Fase 1 — Compreensão do Negócio

Entender o problema antes de tocar no dado

Esta fase não produz gráfico: produz uma pergunta. O papel da ferramenta aqui é acelerar o diálogo com quem conhece o negócio.

1

Protótipo descartável

Com o Dash, um painel provisório fica pronto em minutos. Mostrar um rascunho a quem decide revela desacordos que uma reunião não revelaria.

2

Definição de KPIs

Tentar desenhar o indicador força a pergunta difícil: o que exatamente contamos como cancelamento? A partir de quando?

3

Registro da decisão

Por ser código, a definição do KPI fica versionada. Seis meses depois dá para saber por que o número mudou.

Nosso objetivo de negócio: reduzir a taxa de cancelamento de reservas, identificando quais características se associam ao cancelamento.

Fase 2 — Compreensão dos Dados

Extração e análise exploratória

Extração

```
df = pd.read_csv(URL)
```

O pandas é o conector. Lê CSV, Excel, JSON, SQL, Parquet e APIs — qualquer fonte que o Python alcance, o Plotly desenha.

Análise exploratória

- `df.describe()` — estatísticas descritivas
- `df.info()` — tipos de dado e contagem de não nulos
- `px.box` — distribuição, dispersão e valores atípicos
- `px.imshow` — matriz de correlação
- `df.isna()` + `px.bar` — mapa visual de ausentes

Equivalência com o Power Query

O Power BI traz os painéis “Qualidade da Coluna” e “Perfil da Coluna”, que mostram visualmente quanto falta e como o dado se distribui.

No Plotly esse diagnóstico é escrito, não clicado. Custa mais linhas — e entrega duas coisas que o painel não dá:

- o critério fica explícito e discutível
- a análise roda igual na próxima carga de dados

Fase 3 — Preparação dos Dados

Limpeza, engenharia de features e carga

1

Limpeza

fillna, replace e filtros por condição. Cada decisão fica escrita em uma linha que se pode ler e contestar.

2

Engenharia de features

Colunas novas são atribuições diretas. Equivale à “Coluna Condicional” do Power Query ou ao “Campo Calculado” do Tableau.

3

Formatação e carga

astype define o tipo; to_csv ou to_parquet finalizam. O resultado alimenta o dashboard e qualquer modelo posterior.

A diferença que mais pesa

No Power BI a transformação acontece no Power Query e fica gravada dentro do arquivo .pbix — um binário que o Git não sabe comparar. Aqui o pipeline inteiro é texto: cada alteração aparece no diff, e qualquer integrante consegue revisar o que mudou e por quê.

02

Estudo de caso

119.390 reservas de dois hotéis em Portugal, entre julho de 2015 e agosto de 2017

O problema e o dataset

Hotel Booking Demand — publicado em artigo revisado por pares

Objetivo de negócio

Reduzir a taxa de cancelamento de reservas, identificando quais características da reserva e do cliente mais se associam ao cancelamento — para que a rede possa antecipar e agir.

119.390

reservas
(mínimo exigido: 1.000)

32

atributos
(mínimo exigido: 5)

4

colunas com valores
ausentes, em 4 níveis

37%

das reservas foram
canceladas

Fonte: Kaggle · Publicação original: Antonio, Almeida & Nunes (2019), Data in Brief 22, 41–49 · Licença CC0

Escolhido por ter ausência de dados em quatro intensidades diferentes — o que obriga a quatro decisões distintas.

Extração: importando os dados

O enunciado pede os conectores da ferramenta — aqui, quem conecta é o pandas

Como o dataset entra — notebook 01, célula 2

```
URL = ("https://raw.githubusercontent.com/mendoncaluucas/"
      "DataScience/main/data/raw/hotel_bookings.csv")

df = pd.read_csv(URL)
print(f"{df.shape[0]:,} linhas x {df.shape[1]} colunas")
```

Saída

119.390 linhas x 32 colunas

Uma chamada, sem assistente de importação e sem nenhum passo manual.

Três origens, a mesma chamada

1

URL pública do repositório

O que usamos. Abre no Colab e executa sem nenhum arquivo local.

2

Google Drive montado

Caminho da atividade anterior: `drive.mount()` e leitura da pasta.

3


Upload direto / arquivo local

`pd.read_csv("hotel_bookings.csv")` quando roda na máquina.

O que o Plotly não tem: não existe janela de “Obter Dados” com lista de conectores, como no Power BI. O conector é o pandas — e por isso a lista de fontes é a dele: CSV, Excel, JSON, SQL, Parquet, HTML e APIs.

Diagnóstico: onde faltam dados

O equivalente ao painel “Qualidade da Coluna”, feito em código



O gráfico responde “quanto falta”. A tabela ao lado responde “o que fazer” — e é a justificativa, não o percentual, que decide a estratégia.

O diagnóstico inteiro, em três linhas

```
ausentes = df.isna().sum()
ausentes = ausentes[ausentes > 0].sort_values(ascending=False)
px.bar(ausentes, orientation="h")
```

Quatro níveis, quatro decisões

company 94,3%

Remover a coluna

agent 13,7%

Código 0 = sem agência

country 0,4%

Categoria “Desconhecido”

children 4 registros


Preencher com zero

Ausência não é sempre erro. Em agent, o vazio significa “reserva sem intermediário” — é informação. Preencher com a média destruiria esse significado.

Análise exploratória

Onde se cancela mais, e quando a reserva foi feita


Taxa de cancelamento por tipo de hotel



O hotel urbano cancela 1,5× mais

41,7% contra 27,8% do resort — diferença grande demais para ser acaso.

Antecedência da reserva (lead time) por situação




Reservas antigas cancelam mais

Mediana de 113 dias entre as canceladas, contra 45 das mantidas.

Correlação e hipóteses

O que se move junto com o cancelamento

Correlação entre variáveis numéricas



Hipótese 1

Reservas com maior antecedência cancelam mais.

Confirmada: $r = +0,293$, a maior correlação positiva da matriz.

Hipótese 2

Hóspedes que fazem pedidos especiais cancelam menos.

Confirmada: $r = -0,235$. O pedido funciona como sinal de compromisso.

Escala divergente com cinza no centro: o zero precisa parecer ausência de relação, não um valor qualquer.

O pipeline de preparação

Seis etapas — as três exigidas pelo enunciado em destaque

1

EXIGIDA

Valores ausentes

Quatro estratégias, uma por coluna

2

Valores inconsistentes

meal: “Undefined” e “SC” unificados

3

Registros inválidos

182 linhas (0,15%): sem hóspede ou diária absurda

4

EXIGIDA

Engenharia de features

Seis colunas novas, entre elas receita_estimada

5

EXIGIDA

Remoção de colunas

Quatro removidas — uma por vazamento de dados

6

Tipos e carga

Texto para category: 98,5 MB para 22,4 MB

Resultado: 119.390 → 119.208 linhas · 129.425 células ausentes → zero · memória reduzida em 77%

A etapa 4 em uma linha — o equivalente à “Coluna Condicional” do Power Query:

```
df["receita_estimada"] = (df["adr"] * df["total_noites"]).round(2)
```

O achado

Uma coluna que não devia estar ali

Ao cruzar `reservation_status` com a variável-alvo `is_canceled`, a correspondência é perfeita:

Check-Out	→ <code>is_canceled = 0</code>	75.166
Canceled	→ <code>is_canceled = 1</code>	43.017
No-Show	→ <code>is_canceled = 1</code>	1.207

Removida junto com `reservation_status_date`, pelo mesmo motivo: é a data do desfecho.

Por que isso é grave

A coluna não ajuda a prever o cancelamento: ela é o cancelamento, escrito com outro nome.

Só passa a existir depois que o desfecho aconteceu — exatamente quando a previsão já não serve para nada.

Mantê-la produziria um modelo com 100% de acerto e utilidade zero. É o erro chamado vazamento de dados, e ele engana justamente porque o resultado parece excelente.

Antes e depois

O que mudou do dado bruto ao dado preparado



	Antes	Depois	Observação
Linhas	119.390	119.208	–182 registros inválidos
Colunas	32	32	6 saíram, 6 entraram
Células ausentes	129.425	0	todas tratadas
Memória	98,5 MB	22,4 MB	–77%

Atenção ao número de colunas: 32 antes e 32 depois é coincidência, não ausência de mudança. Seis colunas saíram e seis entraram.

Dashboard exploratório

Quatro painéis, todos usando colunas que só existem depois da preparação

Onde estão os cancelamentos — dados já preparados



10% → 57%

A taxa sobe de forma contínua com a antecedência da reserva.

99%

Reservas não reembolsáveis cancelam quase sempre — resultado contraintuitivo.

61%

O segmento Groups é o que mais cancela: é por onde começar a agir.

Sobre o depósito: é correlação, não causa. O hotel provavelmente exige depósito justamente das reservas que já considera arriscadas.

03

Análise crítica

O que a abordagem em código entrega — e onde uma ferramenta de BI fechada ganha

Da atividade anterior para este trabalho

Mesmas três fases do CRISP-DM, dataset diferente — o que muda é a camada de visualização

	Atividade anterior (Python puro)	Este trabalho (Plotly)
Dataset	Telco Customer Churn — 7.043 × 21	Hotel Bookings — 119.390 × 32
Preparação	pandas	pandas — exatamente o mesmo
Visualização	matplotlib + seaborn	Plotly Express + Graph Objects
Gráficos	countplot · boxplot · heatmap	px.bar · px.box · px.imshow
Resultado	figura PNG estática no notebook	gráfico interativo + dashboard Dash
Entrega	notebook individual no Drive	repositório versionado, cinco integrantes

O que não mudou foi a preparação. As duas atividades limpam os dados com pandas — fillna, replace, astype. O Plotly entra depois, na visualização. Essa é a diferença arquitetural real em relação ao Power BI, onde o Power Query faz as duas coisas dentro da mesma ferramenta.

Low-code vs. código

Ganha ou perde é sempre do ponto de vista do código — os critérios do enunciado vão marcados

Velocidade inicial	Perde	Cinco cliques no Power BI equivalem a trinta linhas aqui.	ENUNCIADO
Curva de aprendizado	Perde	Exige Python e pandas. Não é ferramenta para quem não programa.	ENUNCIADO
Flexibilidade	Ganha	Qualquer transformação que o Python expressa, sem esperar a ferramenta.	ENUNCIADO
Reprodutibilidade	Ganha	O pipeline é texto versionado. O .pbix é binário: o Git não compara.	ENUNCIADO
Trabalho em equipe	Ganha	Cinco pessoas editam e revisam por diff. Um .pbix não abre em duas mãos.	
Custo	Ganha	Licença MIT, sem custo por usuário.	
Governança corporativa	Perde	Sem catálogo, sem permissão por linha, sem portal de distribuição.	

O Plotly tem a sua própria camada low-code — o Chart Studio, que monta gráfico a partir de um CSV sem escrever código — e ela herda este mesmo quadro: ganha em velocidade inicial, perde em reprodutibilidade. Ficamos com a camada de código pelos “ganha” do meio da tabela.

Conclusão

1

O Plotly cobre as três fases, por um caminho diferente

A limpeza acontece no pandas e o Plotly visualiza o resultado. Não há um Power Query embutido — e admitir isso é parte da análise.

2

A justificativa vale mais que a técnica

Remover uma coluna por vazamento de dados exigiu entender o problema, não a ferramenta. Nenhum menu sugere essa decisão.

3

Código é mais lento para começar e mais barato para manter

Custou mais linhas montar. Em compensação, o pipeline inteiro se reconstrói sozinho a partir da fonte original.

Limitação que encontramos: o Plotly não substitui uma plataforma de BI em ambiente corporativo — falta governança, catálogo e distribuição. Ele resolve outro problema.